

FINDICI

Règles de classification automatique des documents administratifs

Référence technique — Septembre 2026

Ce document détaille l'ensemble des critères utilisés par le moteur de détection de Findici pour identifier automatiquement le type d'un document (Carte Nationale d'Identité, Récépissé, Passeport, Acte de naissance, Diplôme, Permis de conduire) à partir d'une simple photo ou d'un PDF, ainsi que les vérifications de cohérence appliquées une fois les champs extraits.

Comment le score de classification est calculé

Aucun modèle d'intelligence artificielle entraîné n'est utilisé pour cette étape : chaque type de document candidat reçoit un score construit à partir de plusieurs signaux détectés sur l'image et dans le texte lu par OCR. Le type ayant le meilleur score est retenu, et un niveau de confiance (en %) est calculé en rapportant ce score au total des scores de tous les types.

Signal	Poids	Principe
Format de l'image	0,4	Le ratio largeur/hauteur de la photo redressée est comparé aux formats attendus (carte, A4 portrait, A4 paysage, page de passeport). Format attendu trouvé → +0,4. Format indéterminé (cadrage imparfait) → +0,1 (neutre, pour ne pas trop pénaliser une mauvaise prise de vue).
Mots-clés OCR	0,5 (proportionnel)	Score ajouté = $0,5 \times (\text{nombre de mots-clés du type trouvés dans le texte} / \text{nombre total de mots-clés définis pour ce type})$.
Mots-clés d'exclusion	-0,3 par mot-clé	Si un mot-clé typique d'un AUTRE type de document est détecté (ex. « permis » trouvé en évaluant une CNI), le score du type évalué est pénalisé d'autant.
Signaux spécifiques	+0,3 / -0,3	Bonus ou pénalité propres à certains types : détection de la zone MRZ pour le passeport, détection d'un tableau de catégories A/B/C/D/E pour le permis (voir tableaux détaillés ci-après).

Confiance finale = score du type retenu ÷ somme des scores de tous les types candidats.

Critères détaillés par type de document

Pour chacun des 6 types reconnus par Findici : le format d'image attendu, les mots-clés recherchés dans le texte OCR, les mots-clés qui pénalisent ce type s'ils sont détectés, les signaux spécifiques éventuels, le format de numéro validé, et les champs extraits une fois le type identifié.

Carte Nationale d'Identité (CNI)

Format attendu	Carte — ratio largeur/hauteur entre 1,35 et 1,80
Mots-clés recherchés	« carte nationale », « identite », « republique du cameroun », « sexe », « taille »
Mots-clés d'exclusion	« permis », « categorie », « diplome », « acte de naissance »
Signal spécifique	Si un tableau de catégories de permis (A/B/C/D/E) est détecté sur une carte, le score CNI est pénalisé de -0,3 (probablement un permis, pas une CNI)
Numéro validé	NIU : exactement 17 chiffres
Champs extraits	Nom, prénom, numéro (NIU), date de naissance, date d'expiration

Récépissé de CNI

Format attendu	A4 portrait ou A4 paysage
Mots-clés recherchés	« recepisse », « titre d'identite provisoire », « delegation generale », « surete nationale »
Mots-clés d'exclusion	Aucun
Signal spécifique	Aucun
Numéro validé	Préfixe 2 lettres parmi AD / CE / ES / EN / NO / SU / LT / OU / NW / SW, suivi de 18 caractères alphanumériques (20 caractères au total)
Champs extraits	Nom, numéro de récépissé, date de délivrance

Passeport	
Format attendu	Page de passeport (ratio 0,75 à 0,95) ou carte
Mots-clés recherchés	« passeport », « passport » — volontairement réduit (voir note)
Mots-clés d'exclusion	Aucun
Signal spécifique	Détection de la zone MRZ (2 lignes de code en bas de la page biodonnées) → bonus de +0,3. Repérée par une ligne de 30 à 44 caractères de l'alphabet ICAO, ou par la présence de « p<cmr »
Numéro validé	Extrait depuis la MRZ : 1 à 2 lettres suivies de 6 à 8 chiffres
Champs extraits	Nom, prénom (zones dédiées, étiquettes bilingues « Nom/Surname », ou en dernier recours la MRZ), numéro, date de naissance, date d'expiration, texte MRZ brut

Note : le mot-clé bilingue « republic of cameroon » a été retiré des critères du passeport — cet en-tête figure aussi sur la CNI, ce qui faisait basculer à tort vers « Passeport » des CNI mal lues par l'OCR.

Acte de naissance	
Format attendu	A4 portrait
Mots-clés recherchés	« acte de naissance », « extrait », « etat civil », « paix - travail - patrie », « officier »
Mots-clés d'exclusion	« diplôme », « permis »
Signal spécifique	Aucun
Numéro validé	Aucun format de numéro spécifique validé
Champs extraits	Nom, date de naissance, lieu de naissance (motif « à/a [Ville] »)

Diplôme	
Format attendu	A4 paysage ou A4 portrait
Mots-clés recherchés	« diplôme », « baccalaureat », « licence », « master », « universite », « atteste »
Mots-clés d'exclusion	Aucun
Signal spécifique	Aucun
Numéro validé	Aucun format de numéro spécifique validé
Champs extraits	Nom, date de délivrance, numéro de matricule (motif « matricule : XXX »)

Permis de conduire

Format attendu	Carte — ratio largeur/hauteur entre 1,35 et 1,80
Mots-clés recherchés	« permis de conduire », « catégorie », « ministère des transports »
Mots-clés d'exclusion	« carte nationale »
Signal spécifique	Détection d'un tableau de catégories (au moins 3 lettres parmi A/B/C/D/E trouvées isolément, combiné au mot « catégorie ») → bonus de +0,3
Numéro validé	Aucun format de numéro spécifique validé
Champs extraits	Nom, date de naissance, date de délivrance, catégories détectées (A, A1, B, C, D, E...)

Règles communes à tous les types de documents

Reconnaissance des dates

Toute date au format jj.mm.aaaa, jj/mm/aaaa ou jj-mm-aaaa est reconnue dans le texte (les trois séparateurs — point, barre oblique, tiret — sont acceptés, car les cartes camerounaises utilisent souvent le point).

Reconnaissance du nom

Le nom est recherché en priorité dans une « zone » dédiée de l'image (quand une zone est définie pour ce type de document). À défaut, une heuristique globale est appliquée : une ligne en MAJUSCULES d'au moins 2 mots, qui n'est pas une ligne de code MRZ, et qui ne contient aucun mot d'une liste noire de termes administratifs (« republique », « cameroun », « carte », « ministere », « identité », « passeport », « permis », « diplôme », etc.) — pour éviter de confondre un en-tête officiel avec un nom de personne.

Vérifications de cohérence après extraction (alertes)

Ces contrôles s'exécutent une fois les champs extraits. Ils ne bloquent jamais l'enregistrement du document : ils ajoutent une alerte affichée à l'utilisateur pour vérification manuelle.

Condition	Alerte déclenchée
CNI	Numéro absent, ou différent de 17 chiffres
Récépissé	Numéro absent, ou différent de 20 caractères
Passeport	Zone MRZ non détectée
Permis	Aucune catégorie (A/B/C/D/E) détectée
Tous types	Une date ne respecte pas le format jj/mm/aaaa
Tous types	Une date (hors date d'expiration) se situe dans le futur
Tous types	Aucun nom détecté du tout

Document de référence technique — projet Findici. Ces critères viennent du document « Critères de différenciation des documents administratifs camerounais » et sont implémentés dans config.py (définitions), classifieur.py (calcul du score) et validator.py (vérifications post-extraction).